

Compte rendu d'avancement

Classification supervisée fonctionnelle par ondelettes
Berlinet, Biau & Rouvière – mémoire de M2 Mathématiques

Auteur : Hippolyte Guigon Encadrant : Prof. Jean-Marc Freyermuth Aix-Marseille
Université 9 septembre 2026

Objet

Ce document fait le point, de façon synthétique, sur les deux axes de travail identifiés lors de notre dernier échange :

- **Axe 1 Données d'entrée / *feature engineering*** : reprendre l'exemple de classification en utilisant les **spectres de fréquences** (périodogrammes) comme entrée de l'algorithme, et non plus les signaux bruts.
- **Axe 2 Représentation commune** : retravailler la règle d'ajout finissant la représentation commune de chaque donnée fonctionnelle, en s'appuyant sur la **fréquence d'utilisation** des caractéristiques temps-fréquence (indices (j, k) des fonctions d'ondelettes), avec **optimisation des paramètres par validation croisée**.

Les deux axes sont implémentés, testés (16/16 tests unitaires au vert) et intégrés au pipeline. Des premiers résultats chiffrés sur ECG200 et sur le jeu *phoneme* (Section 3.1 de l'article) sont donnés en fin de document. Je reste disponible pour un point Zoom à votre retour.

Axe 1 *Feature engineering* : le spectre de fréquences en entrée

Motivation

Dans la Section 3.1 de l'article, les observations ne sont pas les enregistrements de parole bruts mais leurs **log-p périodogrammes**. L'objectif de cet axe est de doter le pipeline de la même transformation, appliquée en amont de la décomposition en ondelettes, afin de comparer méthodologiquement la représentation *domaine temporel* et la représentation *domaine spectral*.

Ce qui a été fait

- **Fonction** `to_periodogram` (module `coefficient_compute.py`) : chaque signal $x_1, \dots, x_T$ est remplacé par son périodogramme $I(\omega_j) = |\hat{x}(\omega_j)|^2$, carré du module de sa transformée de Fourier discrète, estimateur (non consistant) de la densité spectrale (Shumway & Stoffer, *Time Series Analysis*, 4.3) :

$$\hat{x}(\omega_j) = \sum_{t=1}^T x_t e^{-2\pi i \omega_j t}, \quad \omega_j = \frac{j}{T}, \quad j = 1, \dots, \lfloor T/2 \rfloor$$

- **Deux conventions de la 4.3** : (i) **retrait de tendance** avant la DFT (constant = retrait de la moyenne, linear = retrait d'une tendance affine), les tendances polluant les basses fréquences ; (ii) **suppression de l'ordonnée de fréquence nulle** $I(\omega_0)$, non informative après centrage et qui écraserait l'échelle logarithmique.

- **Stabilisation de variance** : le pipeline utilise le log-p riogramme $\tilde{I}(\omega_j) = \log(I(\omega_j) + \varepsilon)$, comme dans le montage *phoneme*.
- **Intégration au pipeline** : la décomposition en ondelettes (db4) et l'étape de réduction de dimension (eq. 2.3-2.5) sont appliquées **indifféremment** à $X(t)$ ou $\tilde{I}(\omega_j)$. Le choix se fait dans configs/config.yaml via input_domain : raw | spectrum | both (le mode both exécute le pipeline une fois par domaine pour comparaison directe).
- **Jeux de données** : ECG200 (via aeon, 2 classes, longueur 96) et **phoneme** (Hastie, Buja & Tibshirani 1995 / TIMIT : 5 classes, log-p riogrammes de longueur 256), reproduisant le cadre de la Section 3.1.
- **Visualisation comparative** (data_visualisation.py) : pour un signal donné, superposition signal brut vs log-p riogramme, vecteur de coefficients DWT et décroissance de l'énergie empirique des coefficients dans les deux domaines (Fig. 1).




Fig. 1 Jeu *phoneme*, classe *iy*. Colonne de gauche : signal brut, vecteur DWT, énergie des coefficients triée. Colonne de droite : idem sur le log-p riogramme. Dans les deux domaines l'énergie se concentre sur une poignée de coefficients, ce qui justifie la réduction de dimension de l'étape suivante.

Axe 2 Représentation commune fondée sur la fréquence d'utilisation

Rappel : la règle d'énergie (eq. 2.4) et sa fragilité

La *représentation commune* est l'application qui envoie toute courbe sur le même sous-ensemble fini S_d de fonctions d'ondelettes :

$$\Phi : x \mapsto \left(\langle x, \psi_{j,k} \rangle \right)_{(j,k) \in S_d} \in \mathbb{R}^d$$

L'article construit S_d en classant les indices (j,k) par **énergie empirique**

$$E_{j,k} = \sum_{i=1}^n X_{i,j,k}^2$$

et en gardant les d plus nerg tiques. Cette r gle n'est **pas robuste** : une seule courbe pr sentant un grand coefficient en (j,k) suffit faire entrer cet indice dans la repr sentation commune , m me si aucune autre courbe ne l'utilise.

Nouvelle r gle : fr quence d'utilisation (q. 2.4)

On classe d sormais les caract ristiques temps-fr quence selon **la fr quence laquelle elles sont effectivement utilis es** travers l' chantillon. Avec un seuil de significativit τ_i propre chaque signal :

$$s_{i,j,k} = \mathbb{1}[|X_{i,j,k}| > \tau_i], \quad \varphi_{j,k} = \frac{1}{n} \sum_{i=1}^n s_{i,j,k}, \quad S_d = \text{top-}d \text{ de } \{\varphi_{j,k}\}$$

Trois r gles de seuil sont impl ment es (significance.rule) :

- top_m : les m coefficients de plus grande amplitude de chaque signal ;
- quantile : coefficients au-dessus du quantile global q de $|X|$;
- universal : seuil universel de Donoho Johnstone $\tau = c \hat{\sigma} \sqrt{2 \ln p}$, avec $\hat{\sigma}$ une chelle de bruit robuste (MAD) des coefficients.

Variante discriminante (usage_discriminant) : on classe par l' cart d'utilisation entre classes

$$\Delta_{j,k} = \left| \varphi_{j,k}^{(1)} - \varphi_{j,k}^{(0)} \right|$$

(variance inter-classes en multiclasse), ce qui vise directement le pouvoir discriminant plut t que la seule fr quence d'usage. La r gle d' nergie d'origine reste disponible comme r f rence (selection_rule : energy).

Phoneme / domaine spectral — deux r gles de repr sentation commune (recouvrement Jaccard des ensembles top-12 : 0.85)




Fig. 2 Jeu *phoneme*, domaine spectral. gauche : la fr quence d'utilisation tri e par rang (r gle q. 2.4, seuil top_m=16) ; une vingtaine de caract ristiques sont utilis es par la quasi-totalit des signaux. droite : nergie empirique tri e (r gle q. 2.4). Les ensembles des 12 premiers indices des deux r gles se recouvrent ici ~ 0.85 (Jaccard) : sur ce jeu propre les deux r gles concordent largement, l' cart attendu se manifestant surtout en pr sence d'aberrations.

Optimisation des param tres par validation crois e

Le seuil de significativit , la dimension retenue et le classifieur sont choisis **conjointement** par validation crois e K-fold sur l'ensemble d'entra nement, en minimisant l'erreur de classification valid e crois e (g n ralisation de l' q. 2.5) :

$$(\hat{\tau}, \hat{d}, \hat{g}) = \arg \min_{(\tau, d, g)} \frac{1}{K} \sum_{f=1}^K \widehat{\text{err}}_f(\tau, d, g)$$

- **Pas de fuite d'information** : le classement des indices (j, k) est **recalculé à l'intérieur de chaque fold**, à partir des seules lignes d'entraînement de ce fold.
- Pour la règle d'énergie, τ disparaît et l'on retrouve exactement la recherche $(\hat{d}, \hat{g})$ de l'article.
- **Grille croisée-validée par défaut** : $\text{top_m} \in \{8, 16, 32, 64\}$, $\text{quantile} \in \{0,80; 0,90; 0,95\}$, $\text{universal} \in \{0,7; 1,0; 1,3\}$; d de 1 à $d_{\max}$; classifieurs W-NN, W-QDA, W-CART, W-FFNN (petit perceptron multicouche, extension au-delà de l'article).
- **Stabilité de la sélection** : on rapporte le **Jaccard moyen par paires** des ensembles d'indices retenus d'un fold à l'autre (1,0 = sélections identiques, 0,0 = disjointes).

Vérification (tests unitaires)

Le comportement recherché est vérifié par des tests dédiés (tests/test_representation.py, 16/16 au vert). En particulier, sur une matrice construite avec une caractéristique modérée mais présente dans *tous* les signaux et une autre réduite à un unique pic aberrant : la règle d'énergie place le pic aberrant en tête, là où la règle d'usage retient la caractéristique réellement partagée et retrograde l'aberration.

Premiers résultats chiffrés

Sélection conjointe (seuil, dimension, classifieur) par validation croisée 5 folds ; $d_{\max} = 50$; ondelette db4 ; seuil de significativité top_m croisé-validé. Métriques calculées sur l'ensemble de test tenu à l'écart. La ligne surlignée est la meilleure exactitude (test) pour chaque jeu de données.

Jeu	Règle	Domaine	Classif.	d	seuil	err. CV	Jaccard	acc.	F1
ecg200	nergie (2.4)	raw	W-FFNN	49	-	0.120	0.98	0.820	0.857
ecg200	nergie (2.4)	spectrum	W-QDA	5	-	0.210	0.80	0.810	0.850
ecg200	usage (2.4)	raw	W-FFNN	34	64	0.110	0.96	0.810	0.853
ecg200	usage (2.4)	spectrum	W-QDA	3	8	0.180	1.00	0.800	0.848
ecg200	usage discrim.	raw	W-FFNN	23	32	0.100	0.79	0.860	0.889
ecg200	usage discrim.	spectrum	W-FFNN	14	64	0.120	0.65	0.860	0.892
phoneme	nergie (2.4)	raw	W-FFNN	39	-	0.100	0.96	0.860	0.853
phoneme	nergie (2.4)	spectrum	W-NN	3	-	0.332	1.00	0.588	0.570
phoneme	usage (2.4)	raw	W-FFNN	36	16	0.100	0.89	0.880	0.873
phoneme	usage (2.4)	spectrum	W-CART	41	32	0.340	0.97	0.652	0.640
phoneme	usage discrim.	raw	W-QDA	8	32	0.072	0.91	0.896	0.891
phoneme	usage discrim.	spectrum	W-QDA	8	64	0.256	0.66	0.796	0.790

err. CV = erreur de classification validée croisée ; Jaccard = stabilité de l'ensemble d'indices sélectionnés entre folds ; seuil = - pour la règle d'énergie (sans seuil).

Lecture rapide

- Les deux axes fonctionnent de bout en bout sur les deux jeux et les deux domaines (temporel / spectral).
- **ECG200 (série temporelle brute) : cas où la comparaison de domaines est pertinente** : les règles d'usage valent ou dépassent la règle d'énergie en erreur CV et en exactitude de test ; la variante *usage discriminant* obtient la meilleure exactitude (0,86 dans les deux domaines) avec une dimension nettement plus faible ($d = 14$ à 23 , contre $d = 49$ pour l'énergie). Le domaine spectral donne des représentations très compactes ($d = 3$ à 14).

- **phoneme** : sur le signal (domaine *raw*), l'usage discriminant atteint 0,90 d'exactitude avec $d = 8$ seulement (contre 0,86 et $d = 39$ pour l'énergie) : gain net : la fois en performance et en compacité.
- **R : serve importante sur phoneme + domaine spectral** : le jeu *phoneme* est d_j constitué de log-p riogrammes ; appliquer `to_periodogram` revient donc à prendre le p riogramme d'un log-p riogramme, transformation sans interprétation physique, ce qui explique la chute de performance (0,59 → 0,65). La comparaison brut/spectre n'a de sens que sur des signaux temporels (ECG200). à discuter : conditionner l'option `spectrum` : la nature du jeu, ou l'ignorer pour phoneme.
- Ces chiffres sont des **points de départ** : une seule graine, pas encore de moyennes et p t es ni d'intervalles de confiance.

Prochaines tapes et points de discussion

- **Benchmark systématique** : énergie vs usage vs usage-discriminant, sur ECG200 et phoneme, domaines brut et spectral, avec répétitions (graines) et intervalles de confiance.
- **Seuil universel par échelle** (niveau par niveau) dans `significance_mask`, plutôt qu'un seuil global.
- **Familles d'ondelettes** : comparer Haar, Daubechies, Symlets, Coiflets.
- **Garanties de consistance** : évaluation empirique des bornes de risque (approximation / estimation / complexité VC) de l'article.
- Question méthodologique : faut-il conserver τ_i *par signal* (choix actuel) ou passer à un seuil global τ commun à tout l'échantillon ? Incidence sur la définition de $\varphi_{j,k}$.
- Question : la variante `usage_discriminant` introduit-elle un risque de sur-apprentissage du critère de sélection qu'il faudrait pénaliser ?

Reproductibilité

- Config : `configs/config.yaml` (jeu, domaine d'entrée, règle de représentation, grille CV).
- Pipeline complet : `python -m functional_supervised_classification.model`.
- Figures exploratoires : `python -m functional_supervised_classification.data_visualisation`.
- Tests : `python tests/test_representation.py` (16/16).
- Modules clés : `coefficient_compute.py` (DWT + p riogramme), `representation.py` (règles de représentation commune), `model.py` (sélection CV conjointe).

Références

A. Berline, G. Biau, L. Rouvière : *Functional Supervised Classification with Wavelets*, Annales de l'ISUP.